


ChemAI: Predict the Cure

Прогнозирование биологической
активности химических соединений



Команда 29_noame | Учебная практика | 2026



Постановка задачи

В проекте нужно построить модель машинного обучения для предсказания биологической активности химических соединений против вируса гриппа.

IC50

Концентрация, при которой
вещество подавляет 50% активности
вируса

CC50

Концентрация, при которой
вещество токсично для 50% клеток

SI

Индекс селективности -
оценка эффективности соединения

Метрика оценки: **RMSE (Root Mean Squared Error)** Усреднённая по трём таргетам. Чем меньше - тем лучше.

Данные и важный момент про SI

Данные хакатона

train.csv

751 строка · 214 колонок · с ответами

test.csv

250 строк · 211 колонок · без ответов

sample_submission.csv

Шаблон файла для отправки

Важно про SI

SI связан с IC50 и CC50, но по условию соревнования **SI нужно предсказывать как отдельную переменную.**

Поэтому в финальном решении:

- для SI обучается отдельная модель

Признаки: **210 молекулярных дескрипторов** (MolWt, TPSA, Chi*, Кappa*, EState, fr_* и др.)

Первый baseline: LinearRegression

Pipeline baseline

1. Загрузка данных
2. Подготовка признаков и таргетов
3. Обучение LinearRegression
4. Расчёт RMSE на validation
5. Создание submission

571.977

Validation mean RMSE

Проблемы baseline: слабое качество + отрицательные предсказания (химические показатели не могут быть отрицательными). Нужна более сложная модель.

Улучшение модели: RandomForestRegressor

369.46

RF (обычный) validation RMSE

365.80

RF tuned validation RMSE

Обработка признаков

- Удалено 33 сильно коррелирующих признака (корреляция > 0.95)
- Удалено 34 почти константных признака (одно значение $> 99\%$ строк)
- Пропуски заполнены медианой (только по train)
- Масштабирование через StandardScaler (fit только на train)

После очистки признаков: **validation RMSE 361.908** (улучшение с 365.80)

Финальный подход: target-specific pipeline

IC50

```
RandomForestRegressor  
min_samples_leaf=3  
max_features=1/3
```

CC50

```
RandomForestRegressor  
min_samples_leaf=5  
max_features=0.5
```

SI

```
RandomForestRegressor  
+ np.log1p() / np.expm1()  
min_samples_leaf=7  
max_features=0.5
```

Почему логарифм для SI?

У таргета SI редкие большие выбросы. Логарифмирование через `np.log1p()` сглаживает их, что улучшило RMSE по SI с 293 до 168.

SI предсказывается отдельной моделью.

Финальный результат

323.025

Validation mean RMSE

323.456

Validation RMSE до Pipeline

Финальный файл

`submission_pipeline_best_params.csv`

- ✓ 250 строк, 4 колонки
- ✓ Нет пропусков
- ✓ Нет отрицательных значений
- ✓ Формат совпадает с `sample_submission`

Улучшения в Pipeline

- K-Fold CV (5 фолдов)
- `sklearn.Pipeline`
- Проверка `log` для IC50

Итог

- Построен воспроизводимый ML-pipeline
- Три таргета предсказаны отдельными моделями
- SI предсказывается моделью
- `random_state=42` зафиксирован везде
- Test не использовался для выбора признаков
- Все решения - по validation RMSE

Лучший validation mean RMSE:

323.025

